ПРОГРАММИРОВАНИЕ НА R

Практика 3.1 к материалу «Введение в ggplot2»

Задания по ggplot2

Подготовил Давид Кристофер

Задания идут по порядку лекции «Введение в ggplot2»: сначала эстетики, атрибуты и наложение точек, затем гистограммы, столбцы и линии. Пишите код в одном скрипте и запускайте задания по очереди: в некоторых заданиях продолжается график из предыдущего.

Перед началом подключите пакет и создайте категориальные версии столбцов `cyl` и `am` — они нужны во многих заданиях:

```
library(ggplot2)
# Число цилиндров и тип коробки передач как категории
mtcars$fcyl <- as.factor(mtcars$cyl)
mtcars$fam <- factor(mtcars$am, labels = c("automatic", "manual"))
```

1. ПЕРВЫЙ ГРАФИК

Набор данных `mtcars` содержит сведения о 32 автомобилях из журнала Motor Trend за 1973 год. Он небольшой, понятный и включает и непрерывные, и категориальные переменные.

1. Подключите пакет `ggplot2` с помощью `library()`.
2. Изучите структуру `mtcars` с помощью `str()`.
3. Постройте диаграмму рассеяния функцией `ggplot()`: отобразите число цилиндров (`cyl`) на ось X, а расход в милях на галлон (`mpg`) — на ось Y.

2. ТИП СТОЛБЦА ОПРЕДЕЛЯЕТ ВИД ГРАФИКА

График из предыдущего задания не очень удачен. Число цилиндров `cyl` — категориальная переменная, но в `mtcars` она хранится как числовая. Это вводит в заблуждение: график не соответствует настоящему типу данных. Нужно явно сообщить `ggplot2`, что `cyl` — категория.

1. Измените команду `ggplot()`: оберните `cyl` в `factor()`.

На оси X останутся только значения, которые есть в данных: 4, 6 и 8, без 5 и 7.

3. ОТОБРАЖЕНИЕ СТОЛБЦОВ НА ЭСТЕТИКИ

1. Добавьте эстетику цвета (`color`) и отобразите на неё объём двигателя `disp`.
2. Теперь отобразите `disp` на эстетику размера (`size`).

4. КАКИЕ ПЕРЕМЕННЫЕ ПОДХОДЯТ ЭСТЕТИКЕ

Выполните в консоли:

```
ggplot(mtcars, aes(wt, mpg, shape = disp)) +
  geom_point()
```

Команда выдаёт ошибку. Что она означает?

- [ ] `shape` не является допустимым аргументом.
- [ ] `shape` имеет смысл только для категориальных данных, а `disp` — непрерывная переменная.
- [ ] `shape` имеет смысл только для непрерывных данных, а `disp` — категориальная переменная.
- [ ] `shape` нет среди переменных набора данных.
- [ ] `shape` нужно задавать как функцию.

5. ДОБАВЛЯЕМ ГЕОМЕТРИИ

Набор данных `diamonds` из пакета `ggplot2` содержит сведения почти о 54 000 бриллиантов. Среди переменных есть `carat` (масса бриллианта в каратах) и `price` (цена).

1. Изучите `diamonds` с помощью `str()`.
2. Постройте диаграмму рассеяния: `carat` по оси X, `price` по оси Y.
3. Добавьте геометрию со сглаживающей линией тренда.

6. МЕНЯЕМ ГЕОМЕТРИИ

1. Измените код графика из задания 5: отобразите эстетику `color` на переменную `clarity` (чистота камня).
2. Сделайте точки полупрозрачными: задайте аргументу `alpha` значение `0.4`.

Если геометрий несколько, эстетика, заданная в `ggplot()`, действует на все геометрии. Проверьте это.

7. ГРАФИКИ КАК ПЕРЕМЕННЫЕ

График можно сохранить в переменную и потом добавлять к нему слои оператором `+`. Это удобно, когда из одной основы нужно сделать несколько похожих графиков.

1. По данным `diamonds` создайте основу графика: `price` по оси Y, `carat` по оси X. Сохраните её в `plt_price_vs_carat`.
2. Добавьте к `plt_price_vs_carat` слой точек, чтобы получилась диаграмма рассеяния.
3. Задайте слою точек `alpha = 0.2` и сохраните результат в `plt_price_vs_carat_transparent`. Выведите график, набрав имя переменной.
4. Внутри `geom_point()` вызовите `aes()` и отобразите `color` на `clarity`. Сохраните результат в `plt_price_vs_carat_by_clarity` и выведите его.

8. ЭСТЕТИКИ: ЦВЕТ, ФОРМА И РАЗМЕР

Используйте столбец `fcyl`, созданный в начале: это `cyl`, преобразованный в фактор.

1. Отобразите `mpg` на эстетику `x`, а `fcyl` — на `y`.
2. Поменяйте отображения местами: `fcyl` на `x`, `mpg` на `y`.
3. Отобразите `wt` на `x`, `mpg` на `y`, а `fcyl` — на `color`.
4. Измените слой точек последнего графика: задайте `shape = 1` и увеличьте размер `size` до 4.

Аргументы `x` и `y` в `aes()` обычно не называют: они почти всегда идут первыми. Остальные аргументы называют.

9. ЭСТЕТИКИ: COLOR И FILL

Обычно эстетика `color` меняет *контур* геометрии, а `fill` — *заливку*. У `geom_point()` исключение: цвет точки задаёт `color`, а не `fill`. Но у некоторых форм поведение особое.

По умолчанию `geom_point()` рисует `shape = 19` — сплошной круг. Форма `shape = 21` — круг, у которого *можно* задать и заливку `fill`, *и* контур `color`. Так на одну точку можно отобразить две эстетики.

Все значения `shape` описаны в справке к функции `points()`: `?points`.

1. Используйте столбец `fam`, созданный в начале: это `am`, преобразованный в фактор с уровнями `automatic` и `manual`.
2. Постройте диаграмму рассеяния: `wt` по оси X, `mpg` по оси Y, `fcyl` — на эстетику `fill`. Задайте точкам `shape = 1` и `size = 4`.
3. Замените `shape` на 21 и добавьте `alpha = 0.6`.
4. Отобразите `fam` на `color`.

10. ЭСТЕТИКИ: СРАВНЕНИЕ

Атрибуты могут перекрывать эстетики графика.

1. По данным `mtcars` создайте основу графика `plt_mpg_vs_wt`: `mpg` на `y`, `wt` на `x`.
2. Добавьте слой точек и отобразите категориальное число цилиндров `fcyl` на `size`.
3. Измените отображение: теперь `fcyl` должно отображаться на `alpha`.
4. Ещё раз измените отображение: `fcyl` — на `shape`.
5. Замените геометрию: вместо точек — текст. Измените и отображение: `fcyl` — на `label`.

11. ЭСТЕТИКИ ДЛЯ КАТЕГОРИАЛЬНЫХ И НЕПРЕРЫВНЫХ ПЕРЕМЕННЫХ

Многие эстетики принимают и непрерывные, и категориальные переменные, но некоторые подходят только для категориальных. Какие эстетики применимы только к категориальным данным?

- [ ] `color` и `fill`
- [ ] `alpha` и `size`
- [ ] `label` и `shape`
- [ ] `alpha` и `label`
- [ ] `x` и `y`

12. АТРИБУТЫ: ЦВЕТ, ФОРМА, РАЗМЕР И ПРОЗРАЧНОСТЬ

Теперь аргументы `color`, `shape`, `size` и `alpha` задают *атрибуты* графика — одно значение для всех точек, — а не отображают переменные на *эстетики*.

В R цвет можно задать **шестнадцатеричным кодом**: решётка и по два шестнадцатеричных разряда на красный, зелёный и синий (`"#RRGGBB"`). В шестнадцатеричной системе 16 цифр: от 0 до 9 и от A (10) до F (15). Пара разрядов даёт числа от 0 до 255. `"#000000"` — чёрный (цвета нет), `"#FFFFFF"` — белый, `"#00FFFF"` — бирюзовый (смесь зелёного и синего).

Задайте переменную с цветом:

```
my_blue <- "#4ABEFF"
```

1. Постройте диаграмму рассеяния по `mtcars`: `wt` по оси X, `mpg` по оси Y. Задайте цвет точек `my_blue` и `alpha = 0.6`.
2. Отобразите `fcyl` на заливку `fill`. Задайте точкам цвет `my_blue`, размер `size = 10` и форму `shape = 1`.

13. АТРИБУТЫ ПРОТИВ ЭСТЕТИК

1. Постройте диаграмму рассеяния по `mtcars`: `wt` по оси X, `mpg` по оси Y, `fcyl` — на `color`. Задайте прозрачность точек 0.5.
2. Добавьте текстовый слой: подписи — имена строк `mtcars` (`rownames(mtcars)`), цвет — `"red"`.
3. Вместо текстового слоя добавьте слой точек с `shape = 24` и цветом `"yellow"`.

14. ВСЁ СРАЗУ

В этом задании вы постепенно добавляете эстетики к графику. Набор данных тот же, `mtcars`, но столбцов больше. Описание всех столбцов — в справке `?mtcars`. Нужны столбцы `fcyl` и `fam`, созданные в начале.

Добавлять эстетики не всегда полезно: график усложняется и хуже читается.

1. По данным `mtcars` постройте график `qsec` (Y) против `mpg` (X), цвет — по `fcyl`. Добавьте слой точек.
2. Добавьте ещё одну эстетику: `fam` — на `shape`.
3. Добавьте ещё одну эстетику: отношение `hp / wt` — на `size`.

15. ПОДПИСИ ЭСТЕТИК

Постройте столбчатую диаграмму: число автомобилей с разным числом цилиндров для двух типов коробки передач. Для оформления пригодятся две функции:

- `labs()` задаёт подписи осей x и y; каждый аргумент — строка.
- `scale_fill_manual()` задаёт шкалу цвета заливки. Первый аргумент — заголовок легенды, `values` — именованный вектор цветов.

Исходный код:

```
ggplot(mtcars, aes(fcyl, fill = fam)) +
  geom_bar()
```

1. Подпишите ось X «Число цилиндров», а ось Y — «Количество».
2. Задайте свою шкалу заливки через `scale_fill_manual()`: первый аргумент — `"Коробка передач"`, `values` — `palette`:

```
palette <- c(automatic = "#377EB8", manual = "#E41A1C")
```

3. Задайте позицию `dodge`, чтобы столбики для двух типов коробки стояли рядом.

16. ФИКТИВНАЯ ЭСТЕТИКА

В `ggplot2` можно строить графики по одной переменной, но для этого нужна фиктивная ось Y: отобразите `y` на ноль.

Пределы оси Y можно задать двумя отдельными аргументами или одним числовым вектором: `ylim(lo, hi)` или `ylim(c(lo, hi))`.

1. По данным `mtcars` отобразите `mpg` на x, а `y` — на 0. Постройте диаграмму рассеяния со сдвигом точек `"jitter"`.
2. С помощью `ylim()` задайте пределы оси Y от −2 до 2.

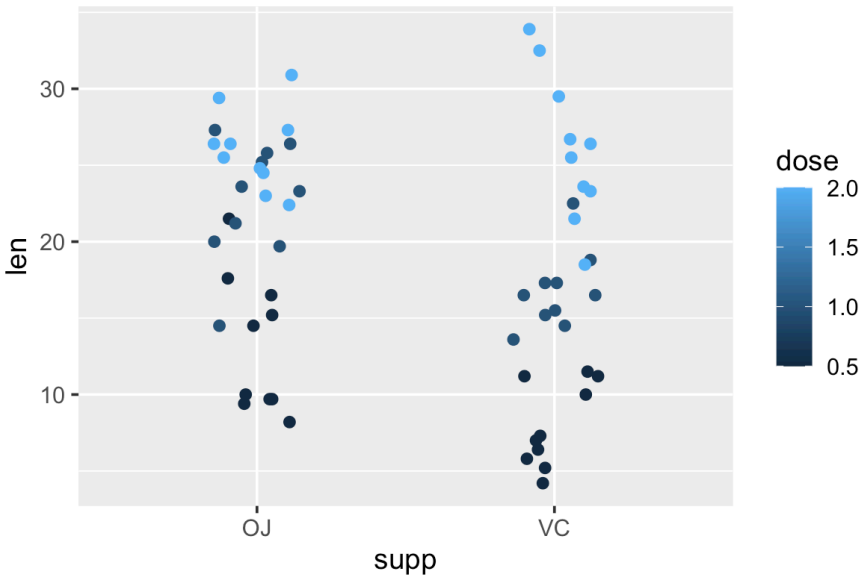
17. ПОДХОДЯЩИЕ ОТОБРАЖЕНИЯ

Неправильное отображение на эстетики запутывает или вводит читателя в заблуждение. Обычно **зависимую** переменную отображают на ось **Y**, а **независимую** — на ось **X**.

В наборе данных `ToothGrowth` три переменные:

Переменная	Описание
`len`	`Длина зубов`
`supp`	`Тип добавки (VC или OJ)`
`dose`	`Доза, мг в день`

Из шести способов отобразить три переменные один показан на рисунке. Какой вариант даёт этот график?



- [ ] `x = supp, y = len, color = dose`
- [ ] `x = dose, y = supp, color = len`
- [ ] `x = len, y = dose, color = supp`
- [ ] `x = len, y = supp, color = dose`
- [ ] `x = supp, y = dose, color = len`

18. НАЛОЖЕНИЕ ТОЧЕК 1: БОЛЬШИЕ НАБОРЫ ДАННЫХ

Диаграммы рассеяния (`geom_point()`) интуитивны, понятны и очень распространены, но *всегда* нужно учитывать **наложение точек**. Особенно в четырёх случаях:

1. Большие наборы данных.
2. Значения, выстроенные вдоль одной оси.
3. Данные низкой точности.
4. Целочисленные данные.

Для сплошных форм обычно советуют прозрачность (*alpha*). Другой вариант — непрозрачные полые формы. Для больших наборов данных с областями высокой плотности подходят маленькие точки.

1. Постройте диаграмму рассеяния по `diamonds`: `price` (Y) против `carat` (X), цвет — по `clarity`.
2. Сделайте точки крошечными: `shape = "."` (один пиксель) — и задайте прозрачность 0.5.
3. Другой вариант: уберите контуры точек, задав `shape = 16`.

19. НАЛОЖЕНИЕ ТОЧЕК 2: ЗНАЧЕНИЯ ВДОЛЬ ОДНОЙ ОСИ

Ещё один случай наложения — значения, выстроенные вдоль одной оси. Так бывает, когда одна ось непрерывная, а другая категориальная. Помогает случайный сдвиг точек (jitter).

1. Создайте основу графика `plt_mpg_vs_fcyl_by_fam`: `fcyl` (X), `mpg` (Y), цвет — по `fam`.
2. Добавьте к основе слой точек.
3. Добавьте случайный сдвиг через `position_jitter()` с `width = 0.3`.
4. Другой вариант: используйте `position_jitterdodge()`. Задайте `jitter.width` и `dodge.width` равными 0.3, чтобы сильнее разделить подгруппы.

20. НАЛОЖЕНИЕ ТОЧЕК 3: ДАННЫЕ НИЗКОЙ ТОЧНОСТИ

Наложение возникает и при измерениях низкой точности, как в наборе `iris`: значения в нём округлены до 1 мм (0.1 см), и многие точки совпадают. Задание похоже на предыдущее, но здесь точки можно сдвигать и по оси X, и по оси Y.

1. Постройте диаграмму рассеяния по `iris`: `Sepal.Length` по оси X, `Sepal.Width` по оси Y, цвет — по `Species`. Точки должны быть прозрачными на 50%.
2. Замените слой точек на слой `geom_jitter()`. Уменьшите сдвиг: задайте `width = 0.1`.
3. Другой способ: в `geom_point()` задайте `position = "jitter"`.
4. Ещё один вариант: передайте в аргумент `position` вызов `position_jitter()` с `width = 0.1`.

21. НАЛОЖЕНИЕ ТОЧЕК 4: ЦЕЛОЧИСЛЕННЫЕ ДАННЫЕ

Целочисленные данные бывают типа `integer` (1, 2, 3...) или категориальными (класс `factor`). `factor` — это особый класс на основе типа `integer`.

Набор `Vocab` содержит число лет обучения (`education`) и результат словарного теста (`vocabulary`) участников Общих социальных опросов США (GSS). Он есть в пакете `carData`, который ставится вместе с пакетом `car`:

```
install.packages("car")
library(car)
Vocab  # теперь набор доступен
```

1. Изучите `Vocab` с помощью `str()`.
2. По данным `Vocab` постройте диаграмму рассеяния `vocabulary` (Y) против `education` (X). Добавьте слой точек.
3. Замените слой точек на слой `geom_jitter()`.
4. Задайте прозрачность 0.2.
5. Сделайте точки полыми кругами (`shape = 1`).

22. ГИСТОГРАММЫ

Гистограмма разбивает непрерывную переменную на интервалы и по умолчанию отображает на эстетику y внутренне рассчитанную переменную `count` — число наблюдений в каждом интервале. Другая внутренняя переменная, `density`, доступна через `after_stat(density)`. Это относительная частота: высота столбика, умноженная на его ширину, даёт долю наблюдений в интервале.

1. По данным `mtcars` отобразите `mpg` на эстетику x и добавьте слой гистограммы `geom_histogram()`.
2. Задайте ширину интервала `binwidth = 1`.
3. Отобразите `y` на внутреннюю переменную `after_stat(density)`, чтобы показать плотность.
4. Задайте цвет заливки `"#51A8C9"`.

В старых материалах вместо `after_stat(density)` пишут `..density..`. Эта запись устарела, но пока работает.

23. ПОЗИЦИИ В ГИСТОГРАММАХ

У `geom_histogram()` — частного случая `geom_bar()` — есть аргумент `position` с такими значениями:

- `stack` (по умолчанию): столбики групп ставятся друг на друга.
- `dodge`: столбики групп ставятся рядом.
- `fill`: столбики групп показывают доли.
- `identity`: значения изображаются как есть, столбики накладываются.

1. Постройте гистограмму `mpg` по `mtcars` с `binwidth = 1`.
2. Измените эстетики: цвет заливки столбиков должен зависеть от `fam`.
3. Измените слой гистограммы: столбики рядом, то есть `"dodge"`.
4. Измените слой гистограммы: столбики вытягиваются на всю высоту и показывают доли, то есть `"fill"`.
5. Измените слой гистограммы: столбики накладываются друг на друга, позиция `"identity"`. Чтобы был виден каждый столбик, задайте `alpha = 0.4`.

24. ПОЗИЦИИ В СТОЛБЧАТЫХ ДИАГРАММАХ

Посмотрим, как аргумент `position` меняет `geom_bar()`. Три варианта:

- `stack`: по умолчанию;
- `dodge`: предпочтительный;
- `fill`: чтобы показать доли.

Здесь используется `geom_bar()`. Функция `geom_col()` — это `geom_bar()`, у которой и `position`, и `stat` равны `"identity"`. Её используют, когда высоты столбиков должны быть точными значениями из данных.

Покажите, сколько автомобилей с каждым числом цилиндров (`fcyl`) имеют автоматическую и механическую коробку передач (`fam`).

1. По данным `mtcars` отобразите `fcyl` на x, заливку — по `fam`. Добавьте слой столбиков `geom_bar()`.
2. Задайте позицию столбиков `"fill"`.
3. Замените позицию на `"dodge"`.

25. ЧАСТИЧНО ПЕРЕКРЫВАЮЩИЕСЯ СТОЛБИКИ

Столбики можно частично наложить друг на друга, настроив сдвиг. Вместо `position = "dodge"` используйте функцию `position_dodge()` — так же, как раньше `position_jitter()`. Сохраните её в объект `posn_d`, чтобы использовать повторно.

Функции `position_dodge()` и `position_jitter()` нужны, чтобы задать, *насколько* сдвигать столбики или точки.

1. По данным `mtcars` отобразите `fcyl` на x, заливку — по `fam`. Добавьте слой столбиков `geom_bar()`.
2. Задайте позицию функцией: `posn_d <- position_dodge(width = 0.2)` и передайте `posn_d` в `geom_bar()`.
3. Задайте столбикам прозрачность 0.6.

26. СТОЛБЦЫ: ПОСЛЕДОВАТЕЛЬНАЯ ПАЛИТРА

Здесь заливка каждого сегмента столбика зависит от порядковой переменной. Для этого лучше всего подходит последовательная палитра. Пример с `mtcars`:

```
ggplot(mtcars, aes(fcyl, fill = fam)) +
  geom_bar() +
  scale_fill_brewer(palette = "Set1")
```

В примере палитра качественная (`Set1`): у `fam` нет порядка. В задании похожий код применяется к набору `Vocab` из задания 21, а обе его переменные порядковые.

Порядковые данные — это качественные данные с упорядоченными категориями: у категорий есть естественный порядок, например от низкого к высокому.

В `carData` столбцы `Vocab` числовые. Чтобы заливка разбивалась по категориям, сделайте их факторами:

```
Vocab$education <- factor(Vocab$education)
Vocab$vocabulary <- factor(Vocab$vocabulary)
```

1. Постройте столбчатую диаграмму по `Vocab`: `education` на x, `vocabulary` на `fill`.
2. Задайте позицию столбиков `"fill"`.
3. Добавьте шкалу заливки `scale_fill_brewer()` с палитрой по умолчанию (без аргументов). Обратите внимание: появится предупреждение, а график будет неполным.
4. Задайте палитру `"Spectral"`.

27. ПРОСТЫЕ ЛИНЕЙНЫЕ ГРАФИКИ

Используем набор `economics` из пакета `ggplot2`. Это временные ряды безработицы и численности населения США от Федерального резервного банка Сент-Луиса.

Сначала посмотрим, как со временем меняются число безработных и уровень безработицы — доля безработных среди населения.

1. Выведите начало набора `economics` с помощью `head()`. Постройте линейный график `unemploy` против `date`.
2. Измените эстетику y так, чтобы она показывала долю безработных среди населения: `unemploy / pop`.

28. НЕСКОЛЬКО ВРЕМЕННЫХ РЯДОВ

Форма данных влияет на то, как их можно построить. Посмотрим на это на примере нескольких временных рядов. Важно, чтобы все линии были на одной шкале и по возможности на одном графике.

`fish.species` содержит мировой улов семи видов лососёвых с 1950 по 2010 год: каждый столбец — вид, каждая строка — год. `fish.tidy` содержит те же данные в трёх столбцах: `Species`, `Year` и `Capture` (по одной переменной в столбце).

1. Загрузите файл `fish.RData`: `load("fish.RData")`.
2. Изучите в консоли структуру `fish.species` и `fish.tidy` с помощью `str()`.
3. Постройте только временной ряд радужной форели (`Rainbow`) с помощью `geom_line()`.
4. Постройте только временной ряд горбуши (`Pink`) с помощью `geom_line()`.
5. Теперь постройте все ряды на одном графике: по данным `fish.tidy` отобразите `Year` на x, `Capture` на y, а внутри `aes()` в `geom_line()` сгруппируйте линии по виду (`group = Species`).
6. Добавьте цвет, чтобы различать ряды: снова постройте `fish.tidy`, на этот раз с цветом по `Species`.

Справка: ggplot2 · after_stat() · position_jitter() · scale_fill_brewer()